

Práctica 1

¿Cómo podemos capturar los datos de la web?

Metadatos

- **Integrantes del grupo:**
 - Agustín Barbatelli Balboa
 - Adrián Cordones Martínez
- **Enlace al sitio web objetivo:**
<https://store.steampowered.com>
- **Enlace al repositorio con el código**
<https://github.com/adriancordones/steam-apps-scraper>
- **Enlace al dataset publicado**
<https://...>
- **Enlace al vídeo de explicación**
<https://...>

1 Contexto

Los datos se han recolectado de la *Steam Store* (enlace: <https://store.steampowered.com>), la plataforma de distribución digital de videojuegos de *Valve Corporation*, líder indiscutible del mercado de videojuegos en PC con más de 50.000 títulos disponibles. Steam es una fuente pertinente y fiable porque centraliza en sus páginas de producto información estructurada y actualizada diariamente sobre precios, reseñas de usuarios, metadatos de contenido y características técnicas de cada juego. A diferencia de fuentes secundarias o agregadores, los datos provienen directamente del vendedor, lo que garantiza su precisión y trazabilidad.

2 Título

El título elegido para el dataset es **Steam Apps Metadata**.

3 Descripción

Este dataset recoge metadatos de aplicaciones publicadas en la *Steam Store*, extraídos mediante web scraping de las páginas individuales de producto. Cada registro corresponde a un juego o aplicación e incluye información identificativa (título, desarrollador, editor), condiciones comerciales (precio, descuento), recepción por parte de los usuarios (número y resumen general de reseñas), características de contenido (DLCs, logros, idiomas, banda

sonora) y clasificación temática (géneros y etiquetas de la comunidad). Los datos reflejan el estado de la tienda en el momento de la extracción (7 de abril de 2026) y cubren los títulos más populares y recientes según los resultados de búsqueda de Steam para España y con la página en español.

4 Representación gráfica




Figura 1: Diagrama simplificado de funcionamiento del Scraper y del dataset resultante

5 Contenido

El dataset contiene 26 campos por registro (no todos obligatorios o siempre presentes). Los campos son los siguientes, agrupados por categoría:

- **id:** identificador numérico de Steam.

- **title**: nombre del producto en la *Steam Store*.
- **date**: fecha de lanzamiento.
- **developer__name**: nombre del desarrollador.
- **publisher__name**: nombre del editor.
- **reviews__total**: número total de reseñas.
- **reviews__recent**: número de reseñas recientes.
- **reviews__total__summary**: valoración global.
- **reviews__recent__summary**: valoración reciente.
- **original__price**: precio base (€).
- **discount__price**: precio con descuento (€).
- **discount__percent**: descuento aplicado (%).
- **achievements__number**: número de logros.
- **langs__number**: número de idiomas soportados.
- **dlds__number**: número de DLCs (sin incluir soundtrack si tiene).
- **has__ost**: booleano, indica si tiene banda sonora en el contenido descargable.
- **is__dlc**: booleano, indica si el producto es en si un DLC.
- **is__ost**: booleano, indica si el producto es en si una banda sonora.
- **short__desc**: descripción breve del producto.
- **dlds**: listado de DLCs (con separador "|").
- **tags**: listado de tags (con separador "|").
- **genres**: listado de géneros (con separador "|").
- **languages**: listado de idiomas soportados (con separador "|").
- **url**: URL de la página del producto.
- **developer__url**: URL de la página del desarrollador.
- **publisher__url**: URL de la página del editor.

6 Propietario

El propietario de los datos es *Valve Corporation*, empresa americana fundada en Kirkland (USA) en 1996 y propietaria de la plataforma Steam. Los datos publicados en Steam son de acceso público a través del navegador, aunque Valve dispone de una API oficial. En esta práctica se ha optado por scraping directo de las páginas HTML en lugar de la API, conforme a los requisitos de la práctica.

Respecto a análisis anteriores similares, ... TODO (faltan la cita y explicarlos).

En cuanto a los principios éticos y legales seguidos, se muestran a continuación:

- Se ha revisado el archivo `robots.txt` de Steam, y se ha comprobado que se permite el acceso de bots genéricos a las páginas que se iban a consultar (principalmente, las secciones de `search/` y `app/`). También se ha forzado que se obedezca de forma automática mediante las `settings` de *Scrapy*.
- No se han extraído datos personales de usuarios.
- Se ha configurado (en el `settings.py` que proporciona *Scrapy*) un `DOWNLOAD_DELAY` de 1 segundo y `CONCURRENT_REQUESTS_PER_DOMAIN` a 1 para no saturar el servidor.

- Se ha utilizado un *User-Agent* que identifica el cliente como un navegador convencional.
- En aplicaciones con contenido para adultos, se solicitaría la edad al usuario y, una vez verificada, esta información se guardaría en una cookie, evitando así volver a pedirla en futuras visitas. Para superar este *age gate*, se ha creado esta cookie manualmente.

7 Inspiración

El dataset puede ser de interés para múltiples análisis en el ámbito de la Ciencia de Datos aplicada a la industria del videojuego. Algunas preguntas que se pueden responder con estos datos son las siguientes:

- ¿El género condiciona el precio final establecido?
- ¿Existe correlación entre el precio y la recepción crítica?
- ¿Qué relación existe entre el número de idiomas soportados y la valoración de los usuarios?
- ¿Los juegos con más DLCs tienden a tener peores reseñas?
- ¿Qué géneros presentan mayor número de logros?
- ¿Qué géneros son más frecuentes?
- ¿Hay géneros con mejor valoraciones que otros?

Respecto a los análisis anteriores... TODO

8 Licencia

Se propone la licencia **CC BY-NC-SA 4.0** (Creative Commons Attribution Non Commercial Share Alike 4.0 International). La elección se justifica por varias razones:

- Los datos provienen de una fuente comercial (Valve/Steam) cuyos términos de servicio no permiten el uso comercial de los datos extraídos.
- ... TODO

9 Código

El proyecto está desarrollado en Python con *Scrapy* como framework principal de scraping. La ejecución está orquestada desde `main.py`, que emplea el `AsyncCrawlerRunner` de *Scrapy* junto con el reactor asíncrono (`AsyncioSelectorReactor`), permitiendo encadenar los dos spiders de forma secuencial dentro de un mismo proceso.

El scraper opera en dos fases. La primera, corre a cargo de `LinksSpider`, y recorre las páginas de resultados de búsqueda de Steam y extrae los IDs de las aplicaciones listadas a partir del atributo `data-ds-appid` de cada resultado. La segunda fase, ejecutada por `AppsSpider`, visita la página de producto de cada ID recogido y extrae sus metadatos mediante selectores CSS. Los datos se exportan automáticamente a un fichero CSV a través del mecanismo `FEEDS` de Scrapy.

Las principales dificultades afrontadas han sido ... (TODO)

10 Dataset

El dataset resultante se ha publicado en *Zenodo* en formato CSV con el siguiente DOI: ... (TODO). Incluye un registro por aplicación de Steam, con los 26 campos descritos en el apartado 5. También se encuentra disponible en la carpeta /dataset del repositorio de *Github*.

URL: <https://doi.org/...> (TODO)

11 Vídeo

En este vídeo explicativo se presenta el contexto del proyecto, se describe la arquitectura del scraper y se comentan las principales decisiones técnicas adoptadas.

URL: <https://drive.google.com/...> (TODO)

Participación de los integrantes

A continuación, se muestra la tabla de firmas que recoge la contribución de cada integrante a la práctica.

Contribuciones	Firma
Investigación previa	ACM, ABB
Redacción de las respuestas	ACM, ABB
Desarrollo del código	ACM, ABB
Participación en el vídeo	ACM, ABB

Referencias

- Subirats Maté, L. y Calvo González, M. (2019) Web scraping. Barcelona: Editorial UOC.
- Lawson, R. (2015) Web Scraping with Python: Successfully scrape data from any website with the power of Python. Birmingham: Packt Publishing. ISBN: 9781782164364.
- Scrapy developers (2026) Scrapy documentation (versión 2.14.2). [En línea]. URL: <https://docs.scrapy.org/en/latest/> [Consultado: abril de 2026].
- Valve Corporation (2026) Steam Store. [En línea]. URL: <https://store.steampowered.com> [Consultado: abril de 2026].