

Práctica 1

¿Cómo podemos capturar los datos de la web?

Metadatos

- **Integrantes del grupo:**
 - Agustín Barbatelli Balboa
 - Adrián Cordones Martínez
- **Enlace al sitio web objetivo:**
<https://store.steampowered.com>
- **Enlace al repositorio con el código**
<https://github.com/adriancordones/steam-apps-scraper>
- **Enlace al dataset publicado**
<https://doi.org/10.5281/zenodo.19474687>
- **Enlace al vídeo de explicación**
https://drive.google.com/file/d/1_4P-0rC_je84u0unaYbk-dy7oaR2G-kC/view

1 Contexto

Los datos se han recolectado de la *Steam Store* (enlace: <https://store.steampowered.com>), la plataforma de distribución digital de videojuegos de *Valve Corporation*, líder indiscutible del mercado de videojuegos en PC con más de 50.000 títulos disponibles. Steam es una fuente pertinente y fiable porque centraliza en sus páginas de producto información estructurada y actualizada diariamente sobre precios, reseñas de usuarios, metadatos de contenido y características técnicas de cada juego. A diferencia de fuentes secundarias o agregadores, los datos provienen directamente del vendedor, lo que garantiza su precisión y trazabilidad.

2 Título

El título elegido para el dataset es **Steam Apps Metadata**.

3 Descripción

Este dataset recoge metadatos de aplicaciones publicadas en la *Steam Store*, extraídos mediante web scraping de las páginas individuales de producto. Cada registro corresponde a un juego o aplicación e incluye información identificativa (título, desarrollador, editor), condiciones comerciales (precio, descuento), recepción por parte de los usuarios (número y resumen general de reseñas), características de contenido (DLCs, logros, idiomas, banda

sonora) y clasificación temática (géneros y etiquetas de la comunidad). Los datos reflejan el estado de la tienda en el momento de la extracción (abril de 2026) y cubren los títulos más populares y recientes según los resultados de búsqueda de Steam para España y con la página en español.

4 Representación gráfica




Figura 1: Diagrama simplificado de funcionamiento del Scraper y del dataset resultante

5 Contenido

El dataset contiene 26 campos por registro (no todos obligatorios ni siempre presentes). Dado que algunos de los datos son de carácter dinámico (pueden variar en el tiempo), hay que tener en cuenta su fecha de extracción: 8 de abril de 2026. Los campos son los siguientes, agrupados por categoría:

- **id**: identificador numérico de Steam.
- **title**: nombre del producto en la *Steam Store*.
- **date**: fecha de lanzamiento.
- **developer__name**: nombre del desarrollador.
- **publisher__name**: nombre del editor.
- **reviews__total**: número total de reseñas.
- **reviews__recent**: número de reseñas recientes.
- **reviews__total__summary**: resumen de valoraciones globales.
- **reviews__recent__summary**: resumen de valoraciones recientes.
- **original__price**: precio base (€).
- **discount__price**: precio con descuento (€).
- **discount__percent**: descuento aplicado (%).
- **achievements__number**: número de logros.
- **langs__number**: número de idiomas soportados.
- **dlds__number**: número de DLCs (sin incluir soundtrack si tiene).
- **has__ost**: booleano, indica si tiene banda sonora en el contenido descargable.
- **is__dlc**: booleano, indica si el producto es en si un DLC.
- **is__ost**: booleano, indica si el producto es en si una banda sonora.
- **short__desc**: descripción breve del producto.
- **dlds**: listado de DLCs (con separador "|").
- **tags**: listado de tags (con separador "|").
- **genres**: listado de géneros (con separador "|").
- **languages**: listado de idiomas soportados (con separador "|").
- **url**: URL de la página del producto.
- **developer__url**: URL de la página del desarrollador.
- **publisher__url**: URL de la página del editor.

6 Propietario

El propietario de los datos es *Valve Corporation*, empresa americana fundada en Kirkland (USA) en 1996 y propietaria de la plataforma Steam. Los datos publicados en Steam son de acceso público a través del navegador o de su app, aunque Valve también dispone de una API oficial. En esta práctica se ha optado por scraping directo de las páginas HTML en lugar de usar su API, conforme a los requisitos de la práctica.

Respecto a análisis anteriores similares, destacan los trabajos de De Luisa et al. [1] y de Teja et al. [2]. Estos estudios han utilizado datos de Steam con metodologías analíticas sobre variables similares a las que se presentan en nuestro dataset. En el primer estudio, investigaron la relación entre la popularidad de los juegos y características extraídas de Steam, prediciendo el número de jugadores en las primeras etapas tras el lanzamiento mediante un enfoque bayesiano, determinando el impacto del precio, el tamaño, los idiomas soportados, la fecha de lanzamiento y los géneros. En el segundo estudio, compararon múltiples modelos de regresión para predecir la valoración de videojuegos a partir de variables de Steam como géneros y número de jugadores, obteniendo en los mejores modelos un R^2 superior al 0,9.

En cuanto a los principios éticos y legales seguidos, se muestran a continuación:

- No se han extraído datos personales de usuarios.
- Se ha revisado el archivo `robots.txt` de Steam, y se ha comprobado que se permite el acceso de bots genéricos a las páginas que se iban a consultar (principalmente, las secciones de `search/` y `app/`). También se ha forzado que se obedezca de forma automática activando `ROBOTSTXT_OBEY` en las `settings` de *Scrapy*.
- Se han establecido unos `DOWNLOAD_DELAY` y `CONCURRENT_REQUESTS_PER_DOMAIN` adecuados para limitar la carga sobre el servidor. Adicionalmente, se ha activado la extensión `AUTOTHROTTLER` de *Scrapy*, que ajusta dinámicamente el intervalo entre peticiones en función de la latencia observada en las respuestas del servidor, eligiendo retardo inicial y el máximo.
- Se ha configurado un *User-Agent* que identifica el cliente como un navegador Firefox convencional, evitando así suplantar a otros scrapers conocidos. Adicionalmente, se han incluido cabeceras HTTP estándar (`Accept`, `Accept-Language`, `DNT`, etc.) que reproducen el comportamiento de un navegador real (el de uno de los integrantes del grupo al acceder a Steam).
- En aplicaciones con contenido para adultos, se solicitaría la edad al usuario y, una vez verificada la mayoría de edad, esta información se guardaría en una cookie, evitando así volver a pedirla en futuras visitas. Para superar este *age gate*, se ha proporcionado la mencionada cookie manualmente.

7 Inspiración

El dataset puede ser de interés para múltiples análisis en el ámbito de la Ciencia de Datos aplicada a la industria del videojuego. Analizar tendencias de consumo puede ayudar a orientar estrategias comerciales basadas en la popularidad, precios y características de los títulos.

Algunas preguntas que se pueden responder con estos datos son las siguientes:

- ¿El género condiciona el precio final establecido?
- ¿Existe correlación entre el precio y la recepción crítica?
- ¿Qué relación existe entre el número de idiomas soportados y la valoración de los usuarios?
- ¿Los juegos con más DLCs tienden a tener peores reseñas?
- ¿Qué géneros presentan mayor número de logros?
- ¿Qué géneros tienen una mayor saturación de mercado?
- ¿Hay géneros con mejores valoraciones en promedio que otros?

Respecto a los análisis anteriores, nuestro dataset comparte con el estudio de De Luisa et al. [1] el interés por variables como el precio, los idiomas soportados y los géneros como factores explicativos. Respecto al trabajo de Teja et al. [2], el dataset generado incluye tanto variables numéricas como categóricas que permitirían reproducir o ampliar su análisis de predicción de valoraciones, añadiendo además información sobre otros campos como DLCs, reseñas recientes y descuentos activos, que no estaban presentes en los datos utilizados por dichos autores.

Vemos que nuestro dataset puede ser útil tanto para análisis predictivos que partan del estado actual de mercado como para análisis descriptivos o exploratorios. Por tanto, explotar los datos públicos de Steam puede ser de interés, especialmente para tener un mejor conocimiento del mercado de videojuegos.

8 Licencia

Se propone la licencia **CC BY-NC-SA 4.0** (Creative Commons Attribution Non Commercial Share Alike 4.0 International) [3]. La elección se justifica por varias razones:

- Los datos provienen de una fuente comercial (Steam) cuyos términos de servicio no permiten el uso comercial de los datos extraídos. El término *NonCommercial* (NoComercial) permite que no se comprometan los derechos del propietario original (Valve) de los datos.
- El término *ShareAlike* (CompartirIgual) garantiza que cualquier trabajo derivado de este mantenga las mismas condiciones de uso, preservando el carácter abierto del dataset.
- El término *Attribution* (Atribución) asegura que los autores del dataset sean reconocidos en trabajos posteriores que lo utilicen, lo que es especialmente relevante teniendo en cuenta que el dataset es accesible de forma pública.
- Teniendo en cuenta que esto es una práctica universitaria, esta licencia también es apropiada porque permite la reutilización y el análisis libre del dataset por parte de otros estudiantes.

9 Código

El proyecto está desarrollado en Python usando *Scrapy* como framework principal de scraping. Las librerías y versiones utilizadas se muestran en el archivo `requirements.txt` del repositorio y a continuación:

```
attrs==26.1.0
Automat==25.4.16
certifi==2026.2.25
cffi==2.0.0
charset-normalizer==3.4.7
constantly==23.10.4
cryptography==46.0.6
cssselect==1.4.0
dataclasses==0.6
DateTime==6.0
defusedxml==0.7.1
filelock==3.25.2
hyperlink==21.0.0
idna==3.11
Incremental==24.11.0
itemadapter==0.13.1
itemloaders==1.4.0
jmespath==1.1.0
lxml==6.0.2
packaging==26.0
parsel==1.11.0
Protego==0.6.0
pyasn1==0.6.3
pyasn1_modules==0.4.2
pyparser==3.0
PyDispatcher==2.0.7
pyOpenSSL==26.0.0
pytz==2026.1.post1
queuelib==1.9.0
requests==2.33.1
requests-file==3.0.1
Scrapy==2.14.2
```

```
service-identity==24.2.0
tldextract==5.3.1
Twisted==25.5.0
typing_extensions==4.15.0
urllib3==2.6.3
w3lib==2.4.1
zope.interface==8.2
```

La ejecución está orquestada desde el archivo `main.py`, que emplea el `AsyncCrawlerRunner` de *Scrapy* junto con el reactor asíncrono (`AsyncioSelectorReactor`), permitiendo encadenar los dos spiders de forma secuencial dentro de un mismo proceso.

El scraper opera en dos fases. La primera, corre a cargo de `LinksSpider`, y recorre las páginas de resultados de búsqueda de Steam y extrae los IDs de las aplicaciones listadas a partir del atributo `data-ds-appid` de cada resultado. La segunda fase, ejecutada por `AppsSpider`, visita la página de producto de cada ID recogido y extrae sus metadatos mediante los selectores CSS adecuados. Los datos se exportan automáticamente a un fichero CSV a través del mecanismo **FEEDS** de Scrapy.

Las principales dificultades afrontadas han sido las siguientes:

Gestión del *age gate*.

Como ya se ha indicado antes, Steam redirige automáticamente las páginas de aplicaciones con contenido para adultos a una pantalla de verificación de edad antes de mostrar el contenido. Se han observado dos variantes: una redirección a `/agecheck/app/{id}/` y una pantalla de confirmación sin redirección. En ambos casos el mecanismo de verificación es el mismo: comprobar la presencia de una cookie `birthtime` con un timestamp Unix que indique mayoría de edad. Para resolverlo, se construyó manualmente dicha cookie y se incluyó en todas las peticiones de `AppsSpider` mediante el parámetro `cookies` del objeto `Request` de *Scrapy*.

Control contra bloqueos

En un principio no se habían configurado de forma correcta las opciones del scraper, por lo que se encontraron los siguientes errores:

- **Error 403** (*Forbidden*): el servidor ha recibido la petición, pero rechaza autorizarla.
- **Error 429** (*Too Many Requests*): demasiadas peticiones en poco tiempo.

El primer error ocurría cuando el `DOWNLOAD_DELAY` era demasiado pequeño, de modo que el servidor directamente bloqueaba todas las peticiones entrantes. El segundo error sucedía cuando se activó correctamente el `DOWNLOAD_DELAY` y el `AUTOTHROTTLE`, pero el número de peticiones por minuto era superior a las que Steam permitía, por lo que aún algunas eran bloqueadas. Tras pocas iteraciones, se encontraron los valores óptimos en los que Steam permitía todas las peticiones entrantes, evitando saturar el servidor, aplicando los **settings** que se han mencionado en el apartado 6.

Variabilidad en la estructura de las páginas de apps.

No todas las páginas de producto presentan sus datos de la misma forma. Por ello, se ha tenido que realizar una exploración previa y hacer que el scraper distinga según cada caso. Entre los casos más complejos que se han gestionado han estado el del precio y las reseñas.

Para los precios se identificaron dos estructuras distintas: precio regular sin descuento, representado por el elemento `div.game_purchase_price.price` y precio con descuento activo, donde el precio original

aparece en `div.discount_original_price`, el precio final en `div.discount_final_price` y el porcentaje en `div.discount_pct`. El código gestiona estas situaciones de forma explícita, registrando un *warning* cuando ninguna de las estructuras conocidas es detectada (ayudando así a hacer debug de estas situaciones). Adicionalmente estarían los casos de la *Free2Play* que se han excluido en la propia búsqueda por no ser de interés analítico en los análisis que se planteaban.

En cuanto a las reseñas, Steam puede presentarlas de formas distintas según el volumen y distribución de las mismas. Cuando existen suficientes reseñas en el idioma del usuario, Steam puede variar la estructura en la que se presentan las reseñas. Principalmente, Steam puede mostrar un bloque `div.outlier_totals`, que contiene dos filas, generalmente con las reseñas globales totales y recientes de forma separada. En otros casos, solo se muestran las reseñas globales a través de `#app_reviews_hash`. Dentro del primer caso, además, puede darse la situación de que el bloque `outlier_totals` contenga únicamente una fila (solo globales) en lugar de las dos habituales (globales y recientes). El código distingue todos estos escenarios mediante comprobaciones explícitas de la longitud de las listas de números de reseñas y valoración promedia extraídos.

Detección y exclusión de contenido descargable no relevante.

La sección de DLCs de un juego puede incluir bandas sonoras listadas como contenido descargable. Para el análisis posterior podría ser relevante distinguir si un juego dispone de banda sonora oficial como DLC separado de si dispone de DLCs de contenido jugable. El scraper filtra los elementos cuyo nombre termina en *soundtrack* antes de construir la lista de DLCs, registrando su presencia en el campo booleano `has_ost`. Adicionalmente, los campos `is_dlc` e `is_ost` detectan si el propio producto scrapeado es en sí mismo un DLC o una banda sonora, mediante la presencia de los elementos `div.game_area_dlc_bubble` y `div.game_area_soundtrack_bubble` respectivamente.

URLs de desarrollador y editor no informativas.

En algunos casos, los enlaces de desarrollador o editor en la página del producto apuntan a <https://store.steampowered.com/search/> en lugar de a una página de desarrollador real. Esto ocurre cuando Steam no tiene una página de perfil propia para ese estudio o publisher. El scraper detecta este caso y almacena `None` en lugar de la URL genérica, que carecería de valor analítico.

10 Dataset

El dataset resultante se ha publicado en *Zenodo* en formato CSV con el siguiente DOI: 10.5281/zenodo.19474687. Incluye un registro por aplicación de Steam, con los 26 campos descritos en el apartado 5. También se encuentra disponible en la carpeta `/dataset` del repositorio de *Github*.

URL: <https://doi.org/10.5281/zenodo.19474687>

11 Vídeo

En este vídeo explicativo se presenta el contexto del proyecto, se describe la arquitectura del scraper y se comentan las principales decisiones técnicas adoptadas.

URL: https://drive.google.com/file/d/1_4P-0rC_je84u0unaYbk-dy7oaR2G-kC/view

Participación de los integrantes

A continuación, se muestra la tabla de firmas que recoge la contribución de cada integrante a la práctica.

Contribuciones	Firma
Investigación previa	<i>ACM, ABB</i>
Redacción de las respuestas	<i>ACM, ABB</i>
Desarrollo del código	<i>ACM, ABB</i>
Participación en el vídeo	<i>ACM, ABB</i>

Referencias

- [1] De Luisa, A., Hartman, J., Nabergoj, D., Pahor, S., Rus, M., Stevanoski, B., Demšar, J. y Štrumbelj, E. (2021). Predicting the Popularity of Games on Steam. arXiv:2110.02896. URL: <https://arxiv.org/abs/2110.02896>
- [2] Teja, A. S., Hanafi, M. L. I. y Qomariyah, N. N. (2023). Predicting Steam Games Rating with Regression. E3S Web of Conferences, ICOBAR 2023. URL: https://www.e3s-conferences.org/articles/e3sconf/pdf/2023/25/e3sconf_icobar2023_02001.pdf
- [3] Creative Commons (2023) Licencia Creative Commons Atribución-NoComercial-CompartirIgual 4.0 Internacional. [En línea]. URL: <https://creativecommons.org/licenses/by-nc-sa/4.0/deed.es> [Consultado: abril de 2026].
- [4] Subirats Maté, L. y Calvo González, M. (2019) Web scraping. Barcelona: Editorial UOC.
- [5] Lawson, R. (2015) Web Scraping with Python: Successfully scrape data from any website with the power of Python. Birmingham: Packt Publishing. ISBN: 9781782164364.
- [6] Scrapy developers (2026) Scrapy documentation (versión 2.14.2). [En línea]. URL: <https://docs.scrapy.org/en/latest/> [Consultado: abril de 2026].
- [7] Valve Corporation (2026) Steam Store. [En línea]. URL: <https://store.steampowered.com> [Consultado: abril de 2026].